PROFESSIONAL PROFILE & PORTFOLIO

Raffi Ainul Afif

Data Engineer | Real-Time Streaming & ETL Specialist

GET IN TOUCH

Kontak & Tautan Resmi

Nomor HP
089671532293

LinkedIn
Raffi Ainul Afif

Discord
raffiainuls

Instagram
@raffiainuls21

Portofolio
https://portfolio.raffs.biz.id/

Email
raffi.ainuls@gmail.com

CAREER JOURNEY

Perjalanan Karir & Transformasi

2022 – 2023

Masa Adaptasi & Belajar

Lulusan IT yang sempat vakum 1 tahun, lalu bangkit mengikuti berbagai bootcamp data intensif.

Nov 2023 – Feb 2025

First Job di Xeratic

Memulai karir profesional sebagai Data Engineer, migrasi 300+ tabel & bangun ETL workflows.

Okt 2025 – Sekarang

Badr Interactive

Menangani proyek nasional SMILE5 sistem vaksin Kemenkes, streaming Kafka & Kubernetes.

WORK EXPERIENCE

Badr Interactive

Data Engineer (Okt 2025 – Sekarang) | Depok, Indonesia

- Terlibat proyek nasional SMILE5 sistem monitoring vaksin Kemenkes bersama UNICC.
- Merancang pipeline streaming real-time menggunakan Debezium, Kafka, RisingWave, dan dbt.
- Monitoring dan troubleshooting cluster Kubernetes untuk keandalan infrastruktur data.

WORK EXPERIENCE

Xeratic

Data Engineer (Nov 2023 – Feb 2025) | Tangerang, Indonesia

- Membangun ETL workflows menggunakan Python, Airflow, dan SQL untuk centralized warehouse.
- Memimpin migrasi data dari AWS Athena ke Alibaba MaxCompute mencakup 300+ tabel.
- Validasi dan refaktorisasi 300+ dashboard (Tableau & Metabase) untuk akurasi performa.

The DE Environment

Nusacode - 1

CLI, Docker PostgreSQL, Exception Handling, & Logging

Bagaimana Tim Data Bekerja?

TIM APPLICANT
BE, FE, QA, Helpdesk
Membangun aplikasi & menghasilkan data.

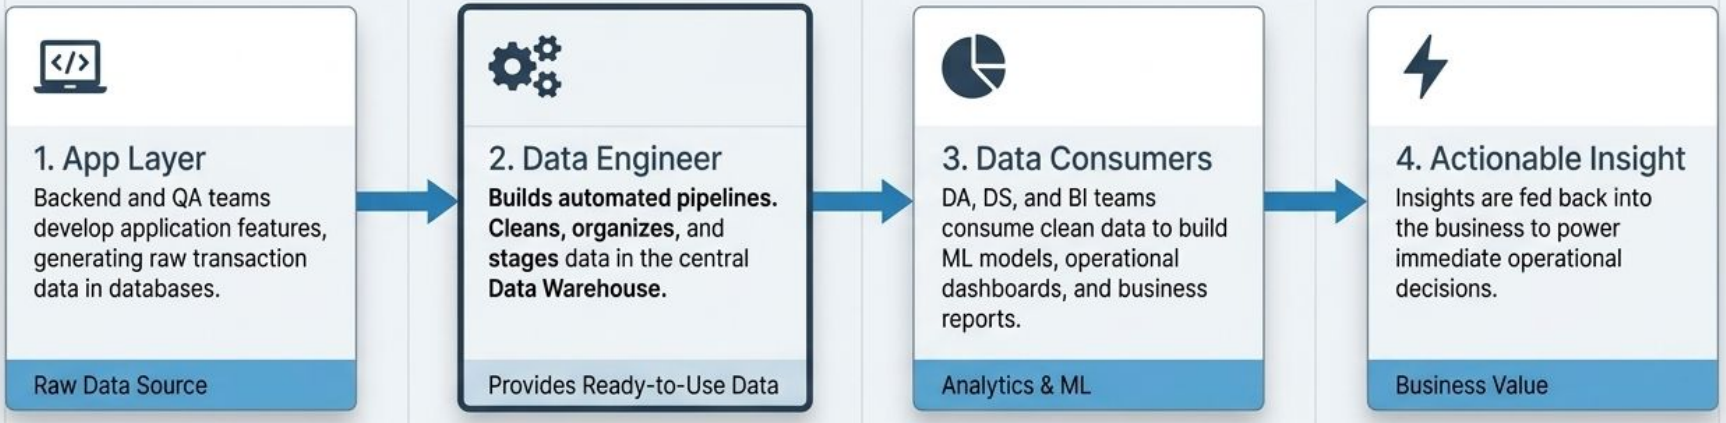
TIM DATA
Mengolah data menjadi Insight & Fitur Pintar.



Contoh Nyata di SMILE 5.0: Fitur notifikasi otomatis 'Stok Hampir Habis' bekerja bukan karena sihir, melainkan berkat pipeline data real-time yang mengolah input Anda secara instan!

NotebookLM

How Does the Data Team Work?



Workflow Dependency

Without the automated pipelines built by the Data Engineer, analysts waste 80% of their time simply cleaning dirty data.

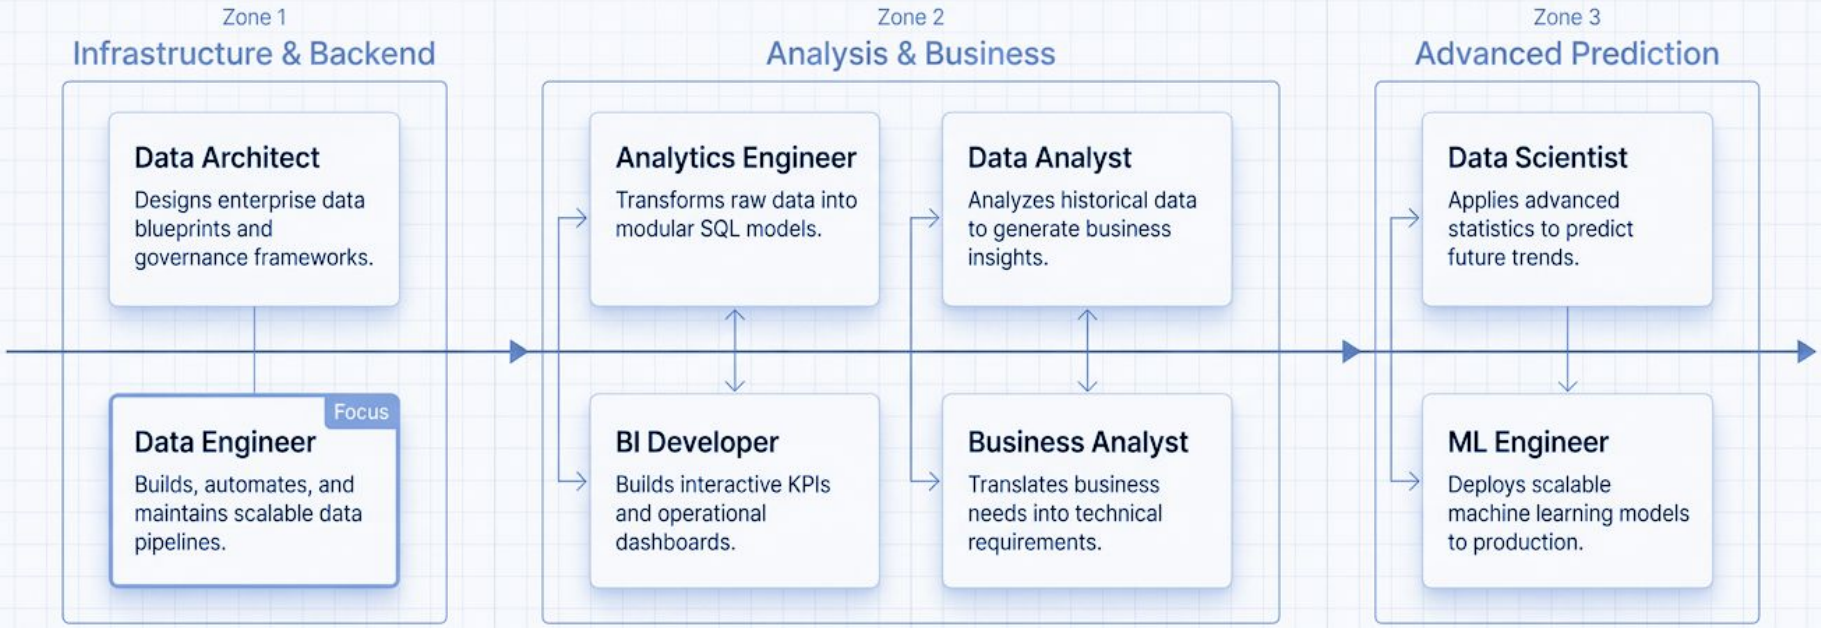
SMILE 5.0 Impact

Critical stock notifications are processed instantly via real-time pipelines, removing the heavy burden of manual database queries.

NotebookLM

The Data Capability Spectrum

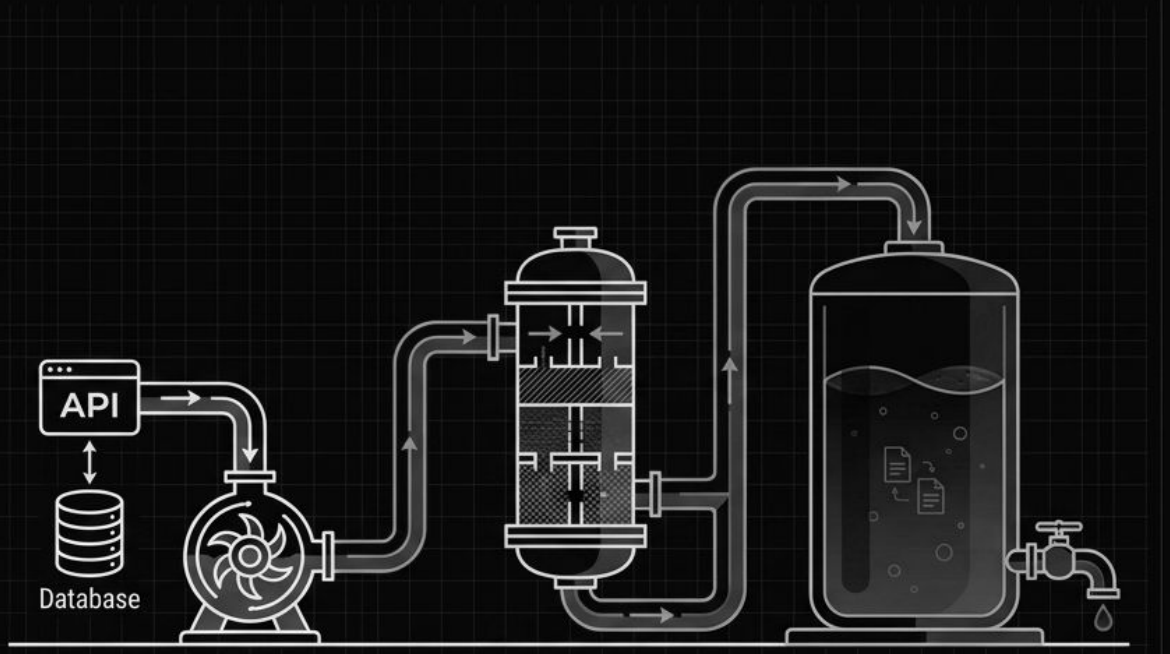
Mapping specializations across the modern data ecosystem.



NotebookLM

Mengenal Sang Arsitek Pipa Data

Data Engineer adalah spesialis yang membangun infrastruktur dasar—memastikan data mengalir lancar, tersimpan aman, dan siap dikonsumsi.



INGEST (Menyedot Air)

Pompa penyedot

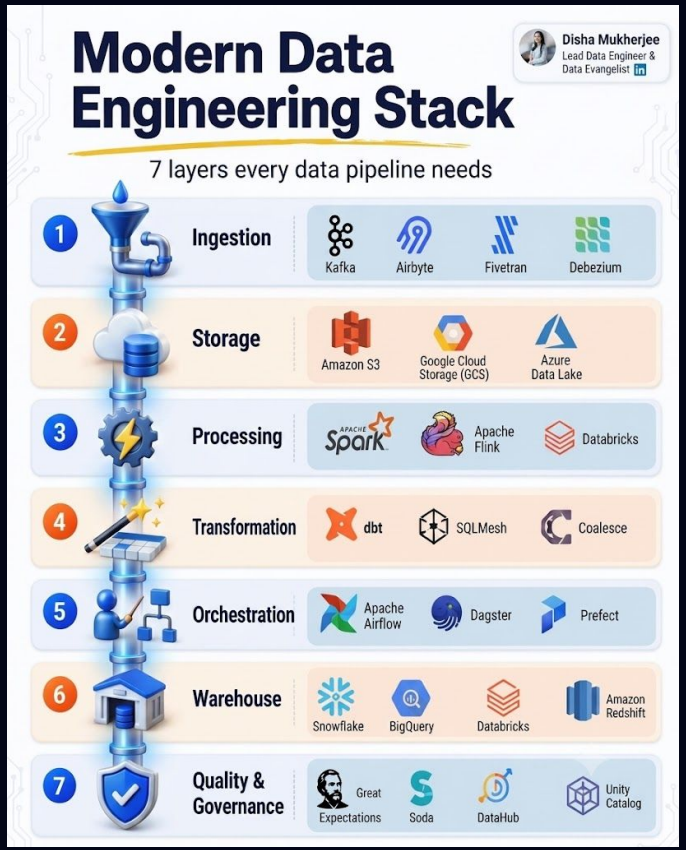
TRANSFORM (Penyaringan)

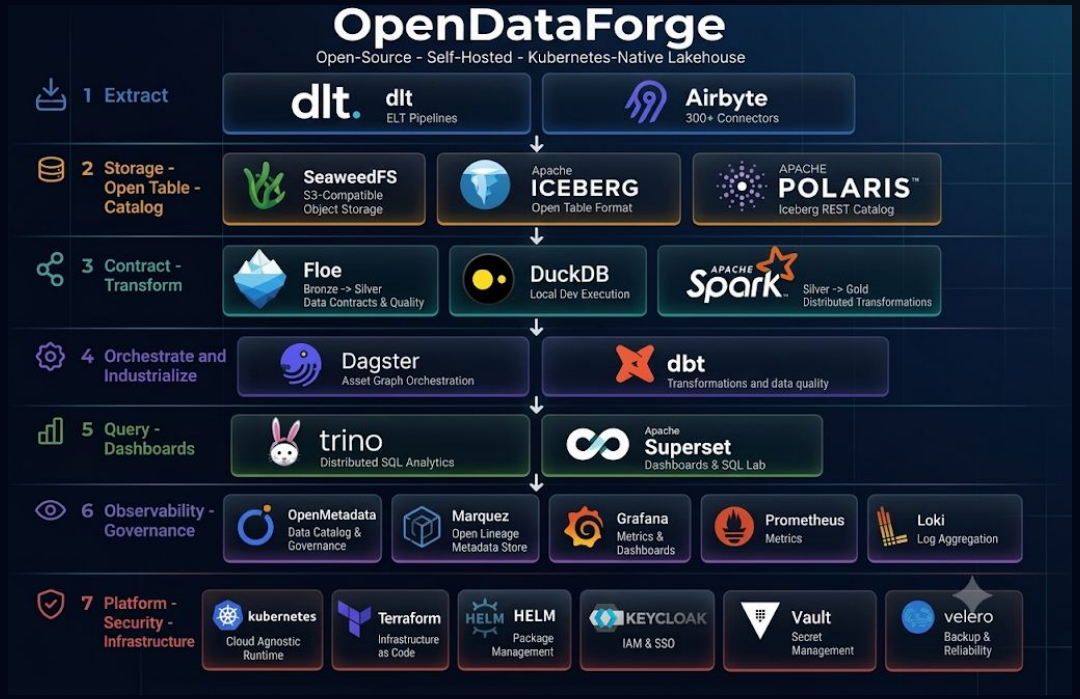
Membasuh data kotor, membuang duplikasi, dan menyeragamkan format (Filter air).

SERVE (Distribusi)

Menyajikan data ke dashboard atau model ML (Tandon raksasa yang siap diminum).

NotebookLM


Modern Data Engineering Stack
Disha Mukherjee
Lead Data Engineer & Data Evangelist
7 layers every data pipeline needs
1 Ingestion
Kafka
Airbyte
Fivetran
Debezium
2 Storage
Amazon S3
Google Cloud Storage (GCS)
Azure Data Lake
3 Processing
Spark
Apache Flink
Databricks
4 Transformation
dbt
SQLMesh
Coalesce
5 Orchestration
Apache Airflow
Dagster
Prefect
6 Warehouse
Snowflake
BigQuery
Databricks
Amazon Redshift
7 Quality & Governance
Great Expectations
Soda
DataHub
Unity Catalog


OpenDataForge
Open-Source - Self-Hosted - Kubernetes-Native Lakehouse
1 Extract
dlt
ELT Pipelines
Airbyte
300+ Connectors
2 Storage - Open Table - Catalog
SeaweedFS
S3-Compatible Object Storage
Apache ICEBERG
Open Table Format
APACHE POLARIS
Iceberg REST Catalog
3 Contract - Transform
Floe
Bronze -> Silver Data Contracts & Quality
DuckDB
Local Dev Execution
Spark
Silver -> Gold Distributed Transformations
4 Orchestrate and Industrialize
Dagster
Asset Graph Orchestration
dbt
Transformations and data quality
5 Query - Dashboards
trino
Distributed SQL Analytics
Apache Superset
Dashboards & SQL Lab
6 Observability - Governance
OpenMetadata
Data Catalog & Governance
Marquez
Open Lineage Metadata Store
Grafana
Metrics & Dashboards
Prometheus
Metrics
Loki
Log Aggregation
7 Platform - Security - Infrastructure
kubernetes
Cloud Agnostic Runtime
Terraform
Infrastructure as Code
HELM
Package Management
KEYCLOAK
IAM & SSO
Vault
Secret Management
velero
Backup & Reliability

Data Engineering

Sumit Gupta
@sumonigupta

Beginner Data Engineer

SQL + Python + Linux + Databases



Junior Data Engineer

ETL/ELT + Data Warehousing + APIs + Git + Scheduling



Mid-Level Data Engineer

Airflow + dbt + Spark/Kafka + Cloud Storage + Data Modeling



Senior Data Engineer

Distributed Systems + Cloud Architecture + Streaming + Governance + Optimization



Modern AI-Ready Data Engineer

Vector Databases + RAG Pipelines + Feature Stores + LLM Data Workflows + Data Quality



PIPELINE PARADIGMS

ETL, ELT, ETLT, & Reverse ETL

📦 ETL (Extract, Transform, Load)

Tradisional / On-Premise

Data diubah & dibersihkan di server perantara **SEBELUM** dimuat ke database target. Menghemat ruang penyimpanan, tapi kurang fleksibel.

🚀 ELT (Extract, Load, Transform)

Modern Cloud Data Warehouse

Data mentah mentah-mentah diserap ke Cloud DW (BigQuery/Snowflake), lalu ditransformasi dengan SQL / dbt. Sangat cepat & fleksibel!

🔄 ETLT (Hybrid Pattern)

Sanitasi Awal + Heavy Transform

Transformasi ringan (masking PII / enkripsi) dilakukan di awal (T1), diserap (L), lalu query analitik berat dijalankan di warehouse (T2).

🔁 Reverse ETL

Operational Analytics

Mengirim data hasil olahan dari Data Warehouse kembali ke aplikasi operasional bisnis (Salesforce, HubSpot, Slack, WhatsApp API).

PROCESSING PATTERNS

Batch vs Micro-Batch vs Streaming

📦 BATCH

Pengiriman Berkala

Latency: 4 – 24 Jam

Data dikumpulkan dulu, baru diproses sekaligus (misal jam 12 malam).
Cocok untuk laporan keuangan harian & agregasi mingguan.
Simpel & efisien biaya.

⏱️ MICRO-BATCH

Pengiriman Chunks

Latency: 1 – 15 Menit

Data diproses dalam kelompok kecil secara berkala (interval pendek).
Contoh: Spark Streaming minibatches.
Jembatan antara batch & real-time streaming.

⚡ STREAMING

Continuous Conveyor Belt

Latency: Detik – Milidetik

Setiap event diproses saat itu juga begitu transaksi terjadi.
Cocok untuk fraud detection, monitoring real-time, live stock.
Tangguh & scalable (Kafka, Debezium, RisingWave).

CASE STUDY: SMILE 5.0

Arsitektur Real-Time Streaming Data Pipeline

🗄️ MySQL

OLTP Database

Sumber data transaksi utama. Binlog mencatat setiap perubahan.

🔍 Debezium

CDC Agent

Membaca binlog MySQL & mengubah transaksi jadi JSON event stream.

⚡ Kafka

Message Bus

Message broker tangguh & durable penampung stream event.

🌊 RisingWave

Stream SQL Engine

Mengeksekusi SQL terus-menerus & membuat Materialized View live.

📊 Datamart

Real-Time Serving

Hasil agregasi real-time siap dikonsumsi Dashboard Kemenkes.

CORE FOUNDATIONS

4 Hal Minimal yang Wajib Dikuasai Data Engineer

🐍 1. PYTHON (Bahasa Logika Pipeline)

Resep & SOP Data

Bahasa standar industri untuk eksekusi skrip ETL/ELT dan data manipulation.
Digunakan untuk parsing JSON, koneksi API/Database, error handling, dan otomatisasi.

🐋 2. DOCKER (Environment Isolation)

Dapur Instan Portable

Menjalankan database (PostgreSQL/MySQL), Kafka, atau Airflow dalam hitungan detik.
Menghindari konflik dependency ("it works on my machine") di dalam tim.

💻 3. CLI (Command Line Interface)

Navigasi & Kontrol Server

Penguasaan dasar terminal Linux/Unix untuk navigasi directory dan server remote.
Eksekusi command docker, file permission, inspeksi log, dan eksekusi skrip background.

🐙 4. GIT (Version Control System)

Buku Sejarah Kode

Mencatat seluruh riwayat perubahan skrip pipeline (siapa, kapan, apa yang berubah).
Memungkinkan kolaborasi tim, branching fitur, dan rollback instan jika terjadi bug.



Analogi Dunia Nyata

"Dapur Restoran Modern" untuk Memahami Tools Data Engineering

Analogi Tools DE

Flow Rapi dalam development

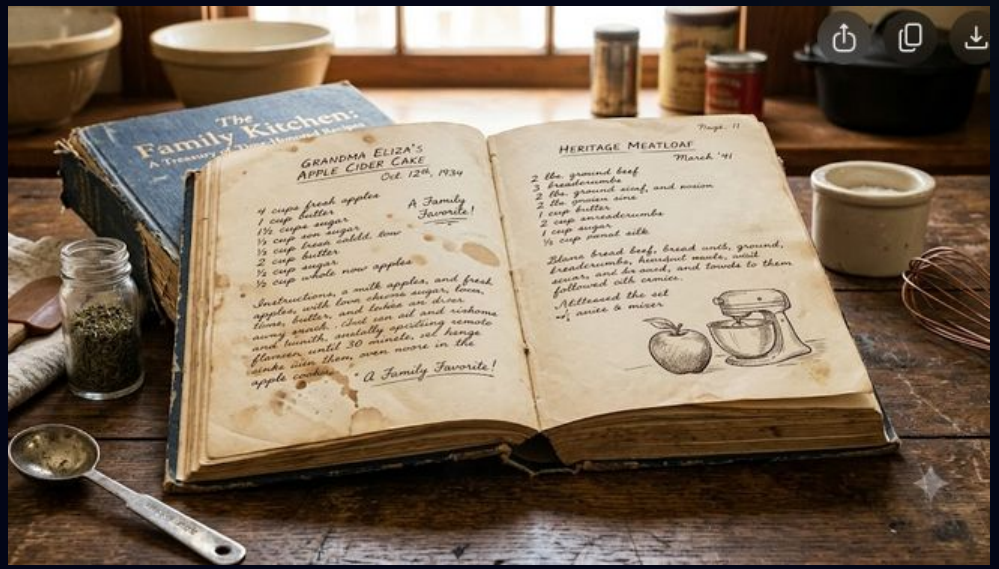


Script Python: SOP & Resep

Instruksi Detail

Python script (.py) adalah kertas berisi instruksi detail tentang langkah apa yang harus dilakukan koki.

Misalnya: kupas bawang, tumis, sajikan. Script inilah yang menggerakkan logika data kita.



Docker: Food Truck

Dapur Portable Instan

Tidak perlu bangun gedung dapur dari nol (install DB manual). Kita sewa **Food Truck** yang sudah lengkap.

PostgreSQL, Python, dan environment lainnya siap pakai hanya dalam 1 klik dengan Docker Compose.



Git: Buku Sejarah Resep

Version Control System

Jika asisten koki mengubah takaran garam dan masakan jadi terlalu asin, kita bisa melacak perubahannya.

Git memungkinkan kita melihat **siapa, kapan, dan apa** yang diubah, serta mengembalikan resep secara instan.



Rencana Alokasi Waktu

10’	20’	45’	30’	15’
Opening & Analogi Dapur	Onboarding Env (Docker/CLI)	Live Code 1: Crash & Error	Live Code 2: Try-Except/Log	Q&A

Perintah Dasar CLI (Terminal)

Command	Arti	Kegunaan
pwd	Print Working Directory	Cek lokasi folder saat ini
ls -la	List All	Tampilkan semua file (termasuk yang tersembunyi)
mkdir	Make Directory	Membuat folder baru untuk proyek
cd ..	Change Directory Up	Keluar folder (naik 1 tingkat ke atas)

Docker PostgreSQL Setup

docker-compose.yml

Konfigurasi container database:

- image: postgres:15-alpine
- ports: "5432:5432"

Up and Running

Jalankan perintah di terminal:

```
docker-compose up -d
```

Bendera -d berarti container berjalan di *background* (detached mode).

Mengapa Pipeline Crash Berbahaya?



Dampak Bisnis

Bayangkan server sedang mengolah **1 Juta transaksi**.

Jika ada 1 data kotor (pembagi 0), script mati di tengah jalan. Sisa data yang bagus tidak akan pernah terproses. Ini kerugian besar!

Solusi: Try-Except (Exception Handling)

- **Try Block:** Membungkus kode yang rentan error (seperti pembagian atau pengambilan key).
- **Except ZeroDivisionError:** Menangkap error pembagi nol dan memberikan aksi alternatif tanpa mematikan program.
- **Except KeyError:** Menangani kasus di mana kolom data (key dictionary) tidak ditemukan.
- **Graceful Degradation:** Data kotor dilewati, script tetap lanjut memproses data bagus lainnya.

Transisi: Print vs Logging

Print()

Output sementara di terminal. Akan hilang jika window ditutup atau script berjalan di cloud/server.

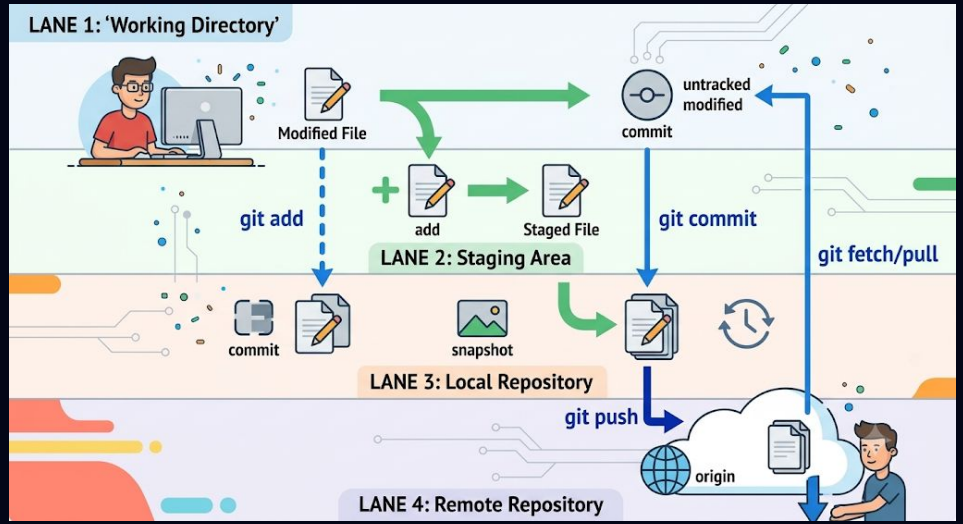
Logging

Output tersimpan permanen dalam file (app.log). Memiliki **Timestamp** untuk riwayat audit.

Log Levels

Kategorisasi pesan: INFO untuk alur normal, ERROR atau CRITICAL untuk masalah serius.

Ringkasan Git Workflow



1. git add . (Bungkus perubahan)

2. git commit -m "pesan" (Beri label)

3. git push (Kirim ke Cloud/GitHub)



Ada Pertanyaan?

Waktunya diskusi

#KeepCoding #DataEngineering



Tugas 1

Coba explore tentang OLAP dan OLTP,

dan coba host dari docker di local

#KeepCoding #DataEngineering