PERTEMUAN 2

Python untuk Data Engineering

Dari script sederhana menuju transformasi data yang siap dipakai pipeline.

CSV → Python → Output

TUJUAN BELAJAR

Apa yang akan kita kuasai?

Sesi ini membangun fondasi Python sebelum masuk ke data cleaning dan pipeline automation.

01

Python dasar

Variabel, tipe data, struktur data, kondisi, perulangan, dan function.

02

Baca data

Membaca file CSV dan JSON dari sumber data sederhana.

03

Pandas & NumPy

Mengenal DataFrame, Series, array, dan inspeksi dataset.

04

Transformasi

Rename kolom, filter data, hitung rata-rata, dan simpan output.

FORMAT FILE

`.ipynb` vs `.py`

Keduanya dapat berisi Python, tetapi cara pakai dan tujuan utamanya berbeda.

.ipynb — Jupyter Notebook

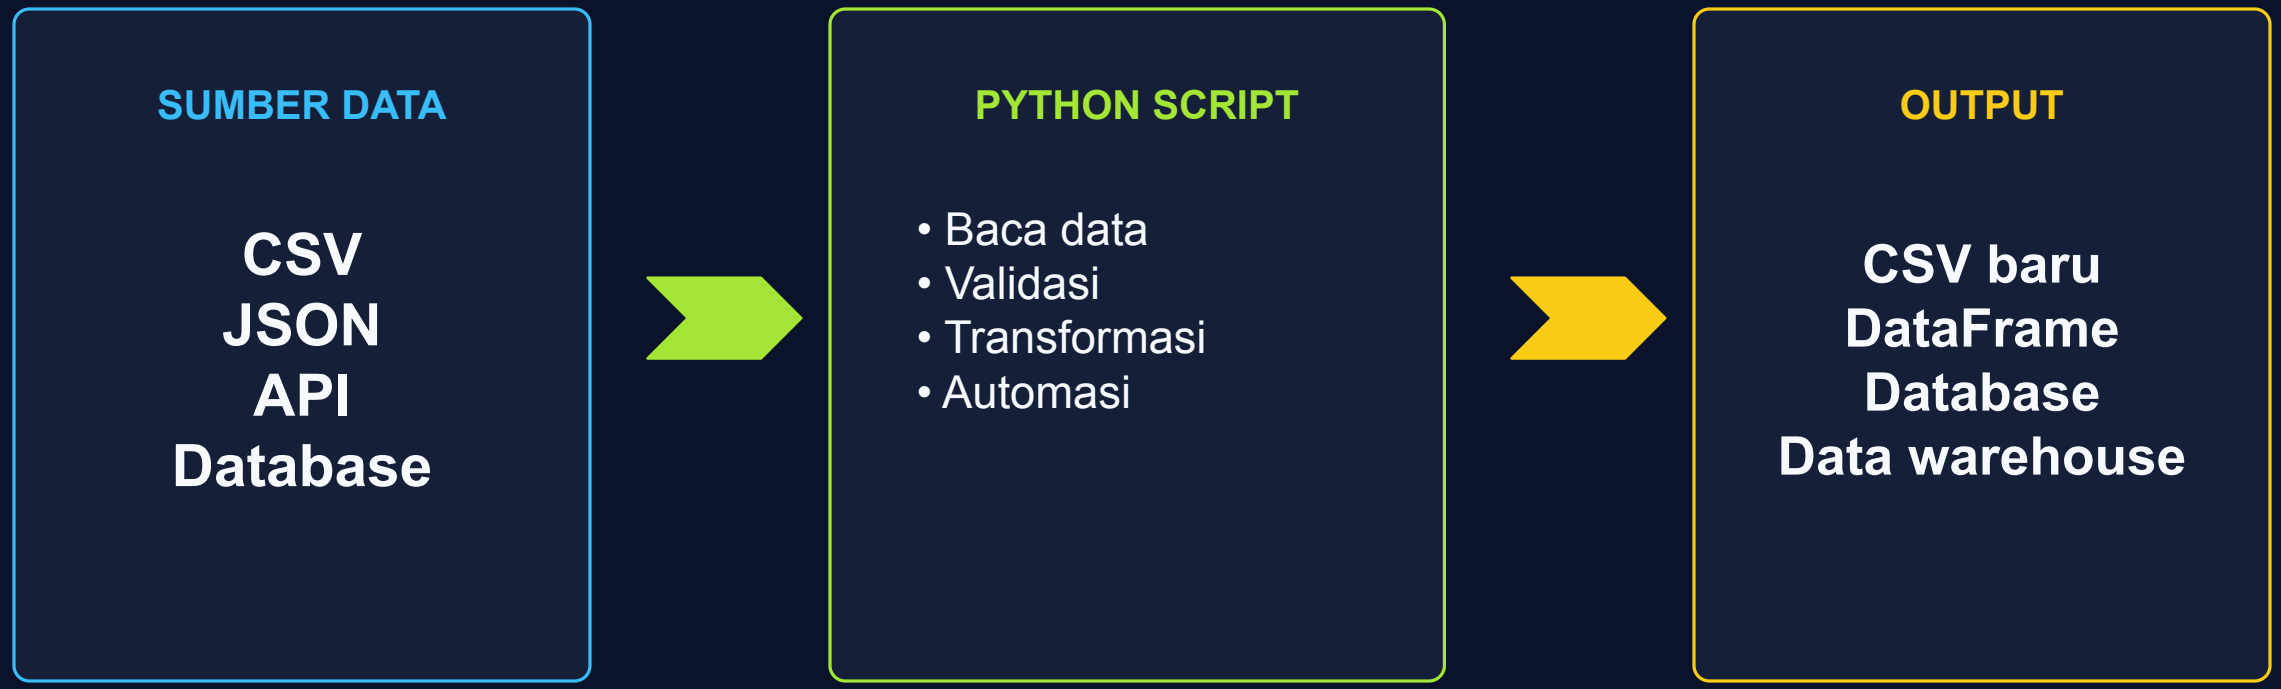
- Kode dibagi menjadi cell
- Output terlihat langsung
- Mendukung markdown, tabel, dan visualisasi
- Cocok untuk eksplorasi dan belajar

.py — Python Script

- Kode dijalankan sebagai script
- Output ke terminal atau file
- Mudah dijadwalkan dan diulang
- Cocok untuk ETL dan production workflow

Python di dalam data engineering

Python menjadi perekat antara sumber data, proses transformasi, dan output.



Blok bangunan sebuah script

Mulai dari data sederhana, lalu gabungkan menjadi alur transformasi.

Variabel

```
name = "transaksi"
amount = 150000
```

Struktur data

```
rows = []
record = {}
```

Kondisi

```
if amount > 100000:
    print("besar")
```

Function

```
def transform(data):
    return data
```

CSV dan JSON sebagai bahan mentah

Kenali bentuk data sebelum melakukan transformasi.

CSV → tabel

```
import pandas as pd

data = pd.read_csv("transaksi.csv")
print(data.head())
```

Periksa kolom, tipe data, dan jumlah baris.

JSON → objek bertingkat

```
import json

with open("data.json") as file:
    data = json.load(file)
```

Perhatikan struktur key dan value.

LIBRARY DATA

Pandas dan NumPy

Gunakan alat yang tepat untuk bentuk pekerjaan yang tepat.

Pandas

- DataFrame untuk data tabular
- Series untuk satu kolom
- Filter, rename, sort, dan agregasi
- Input/output CSV dan JSON

NumPy

- Array numerik
- Operasi matematis efisien
- Fondasi untuk banyak library data
- Membantu perhitungan skala besar

Kenali dataset sebelum mengubahnya

Inspeksi awal membantu kita memahami bentuk dan kualitas data.

Perintah inspeksi

```
data.head()
data.info()
data.describe()
data.columns
data.shape
```

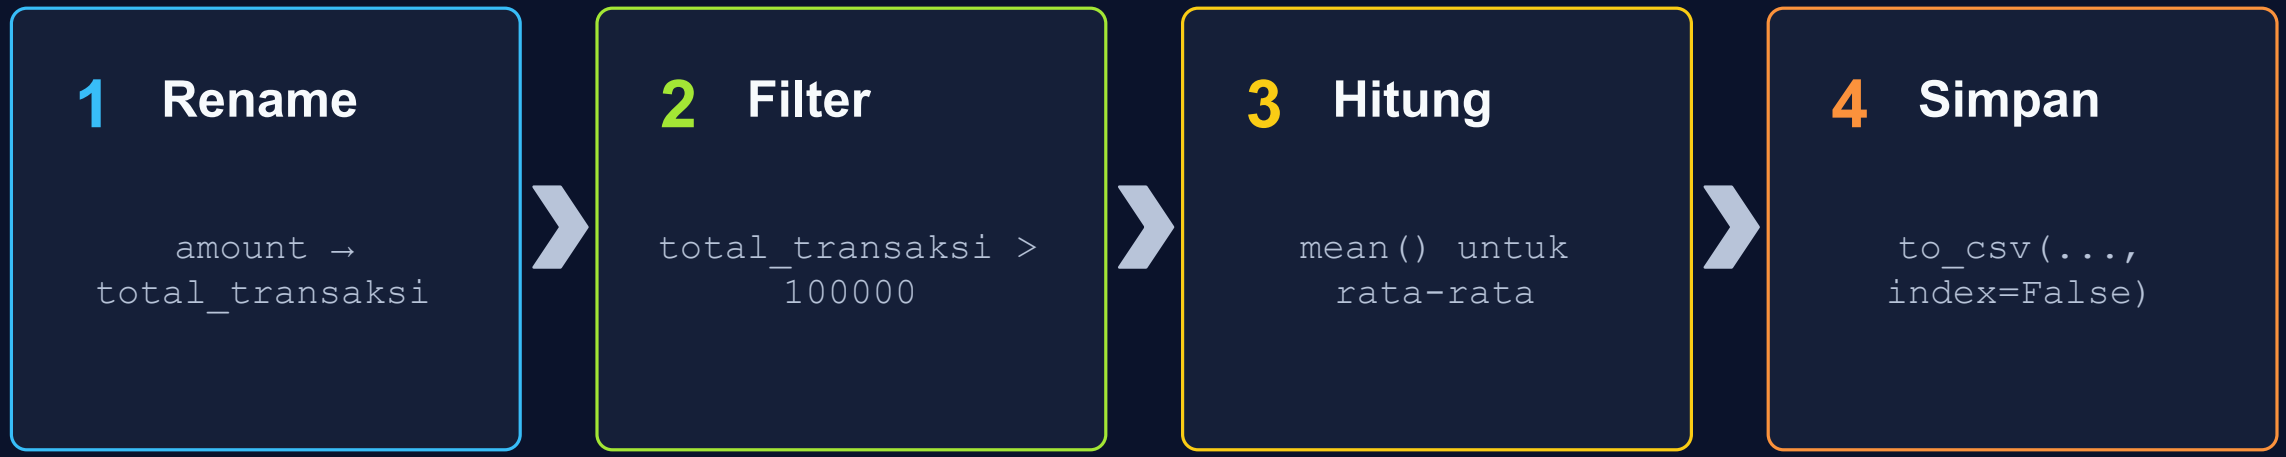
Pertanyaan awal

- Kolom apa saja yang tersedia?
- Berapa banyak baris data?
- Tipe data sudah sesuai?
- Nilai numerik dapat dihitung?

TRANSFORMASI

Dari data mentah menjadi data siap pakai

Praktik sesi ini berfokus pada transformasi sederhana.



Hasil akhirnya adalah file baru yang siap digunakan oleh proses berikutnya.

PRAKTIK

Mini workflow yang akan dibuat

Satu latihan kecil untuk menghubungkan seluruh konsep.



Output dapat digunakan sebagai input untuk pembelajaran data cleaning pada pertemuan berikutnya.

TUGAS

Latihan transformasi dataset CSV

Kerjakan dengan Python dan dokumentasikan prosesnya.

Checklist tugas

- Baca dataset CSV sederhana.
- Rename minimal satu kolom.
- Filter data berdasarkan kondisi.
- Hitung rata-rata kolom numerik.
- Simpan hasil sebagai CSV baru.

Output

1. Notebook atau script Python
2. Dataset input
3. File hasil transformasi
4. Catatan singkat

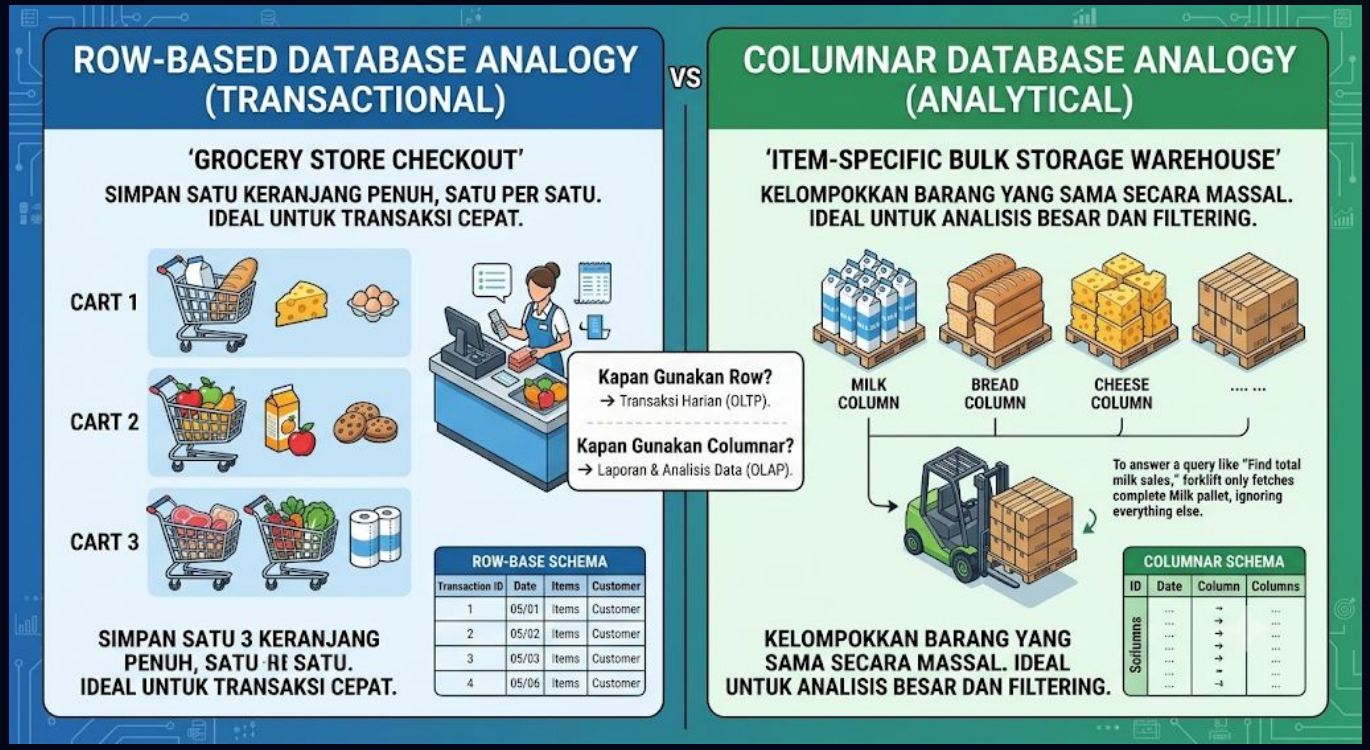
Analogi: OLTP vs OLAP

OLTP (Online Transactional Processing)

Cara Kerja: Setiap kali ada pelanggan memesan makanan, kasir langsung mencatat: *"Meja 5 pesan 1 Nasi Goreng dan 1 Es Teh"* (operasi cepat: *Insert, Update, Delete*)..

OLAP (Online Analytical Processing)

Cara Kerja: Manager tidak peduli siapa yang membeli es teh detik ini. Dia ingin melihat gambaran besar (*Big Picture*): *"Berapa total keuntungan menu Nasi Goreng di seluruh cabang se-Indonesia selama 1 tahun terakhir,*





Ada Pertanyaan?

Waktunya diskusi.



Tugas

read csv (kaggle), transform, write to db