PERTEMUAN 3

Modern Data Architecture and Modelling

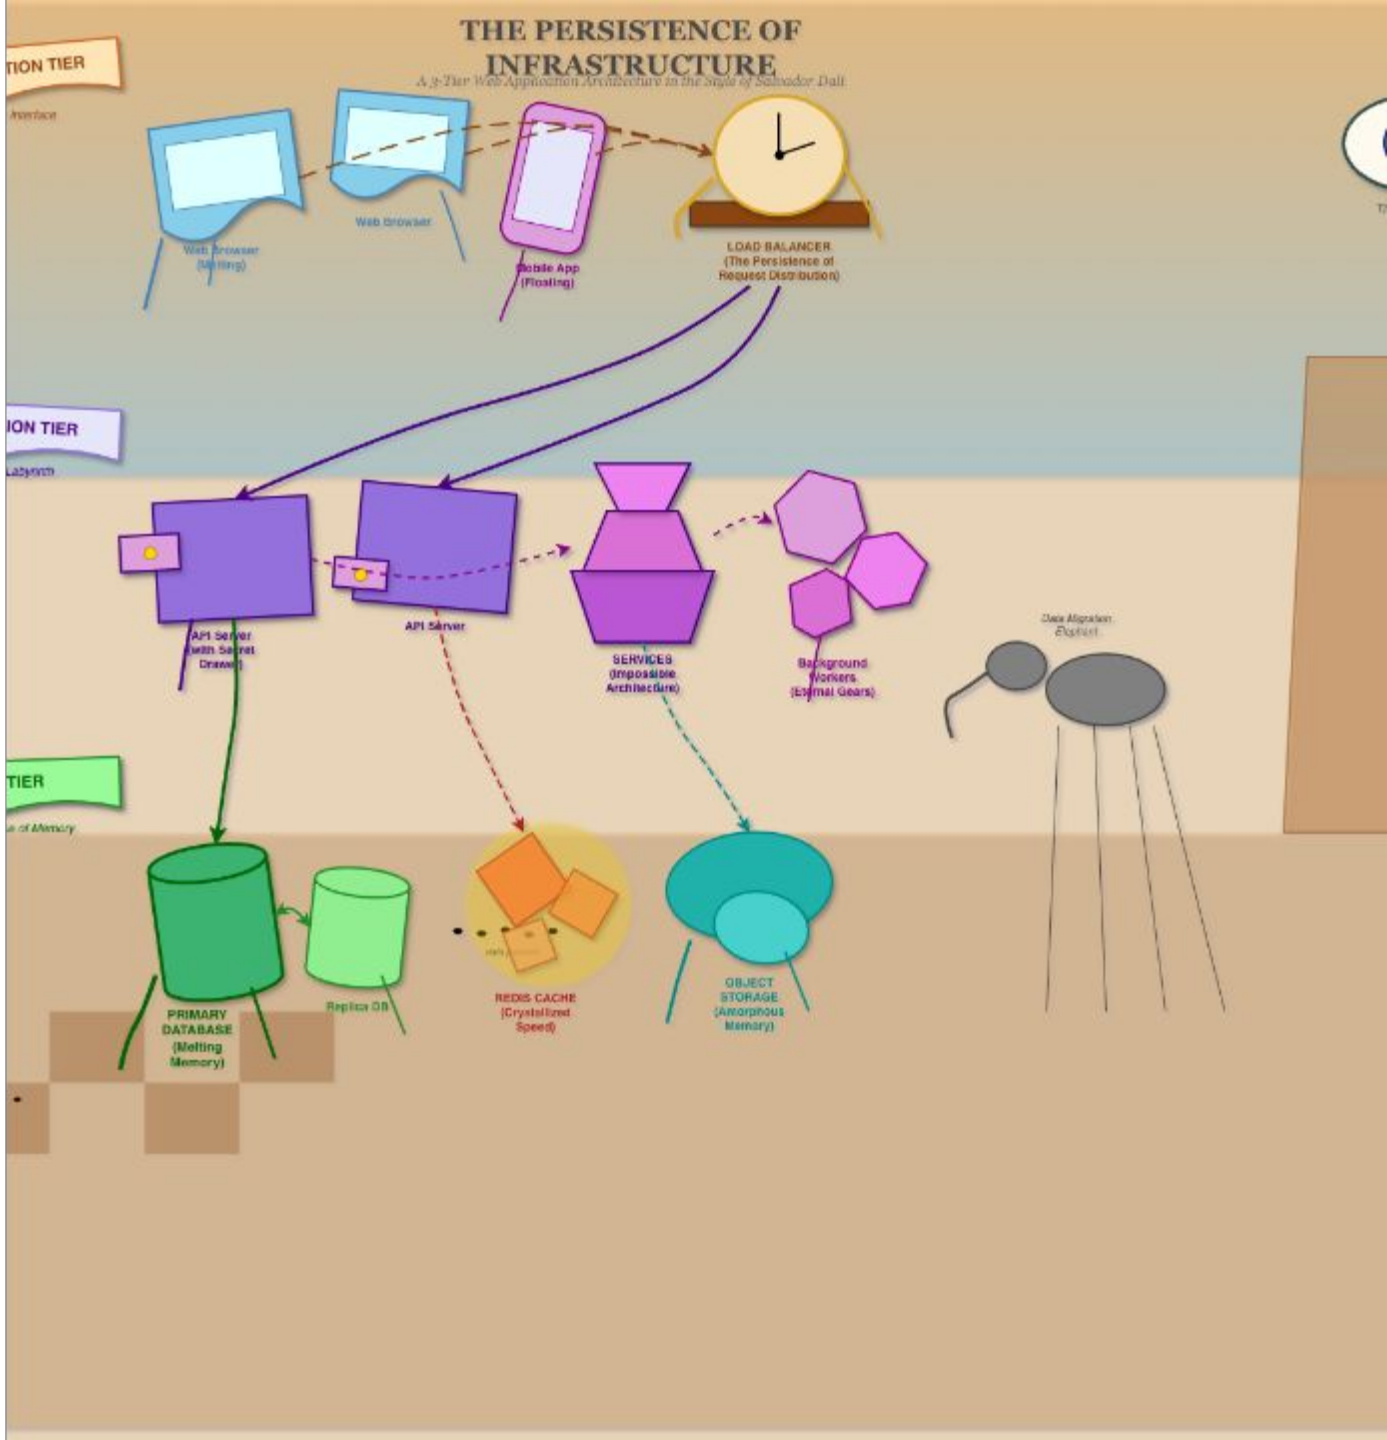
Dari data mentah menuju data yang siap dianalisis dan dimodelkan.

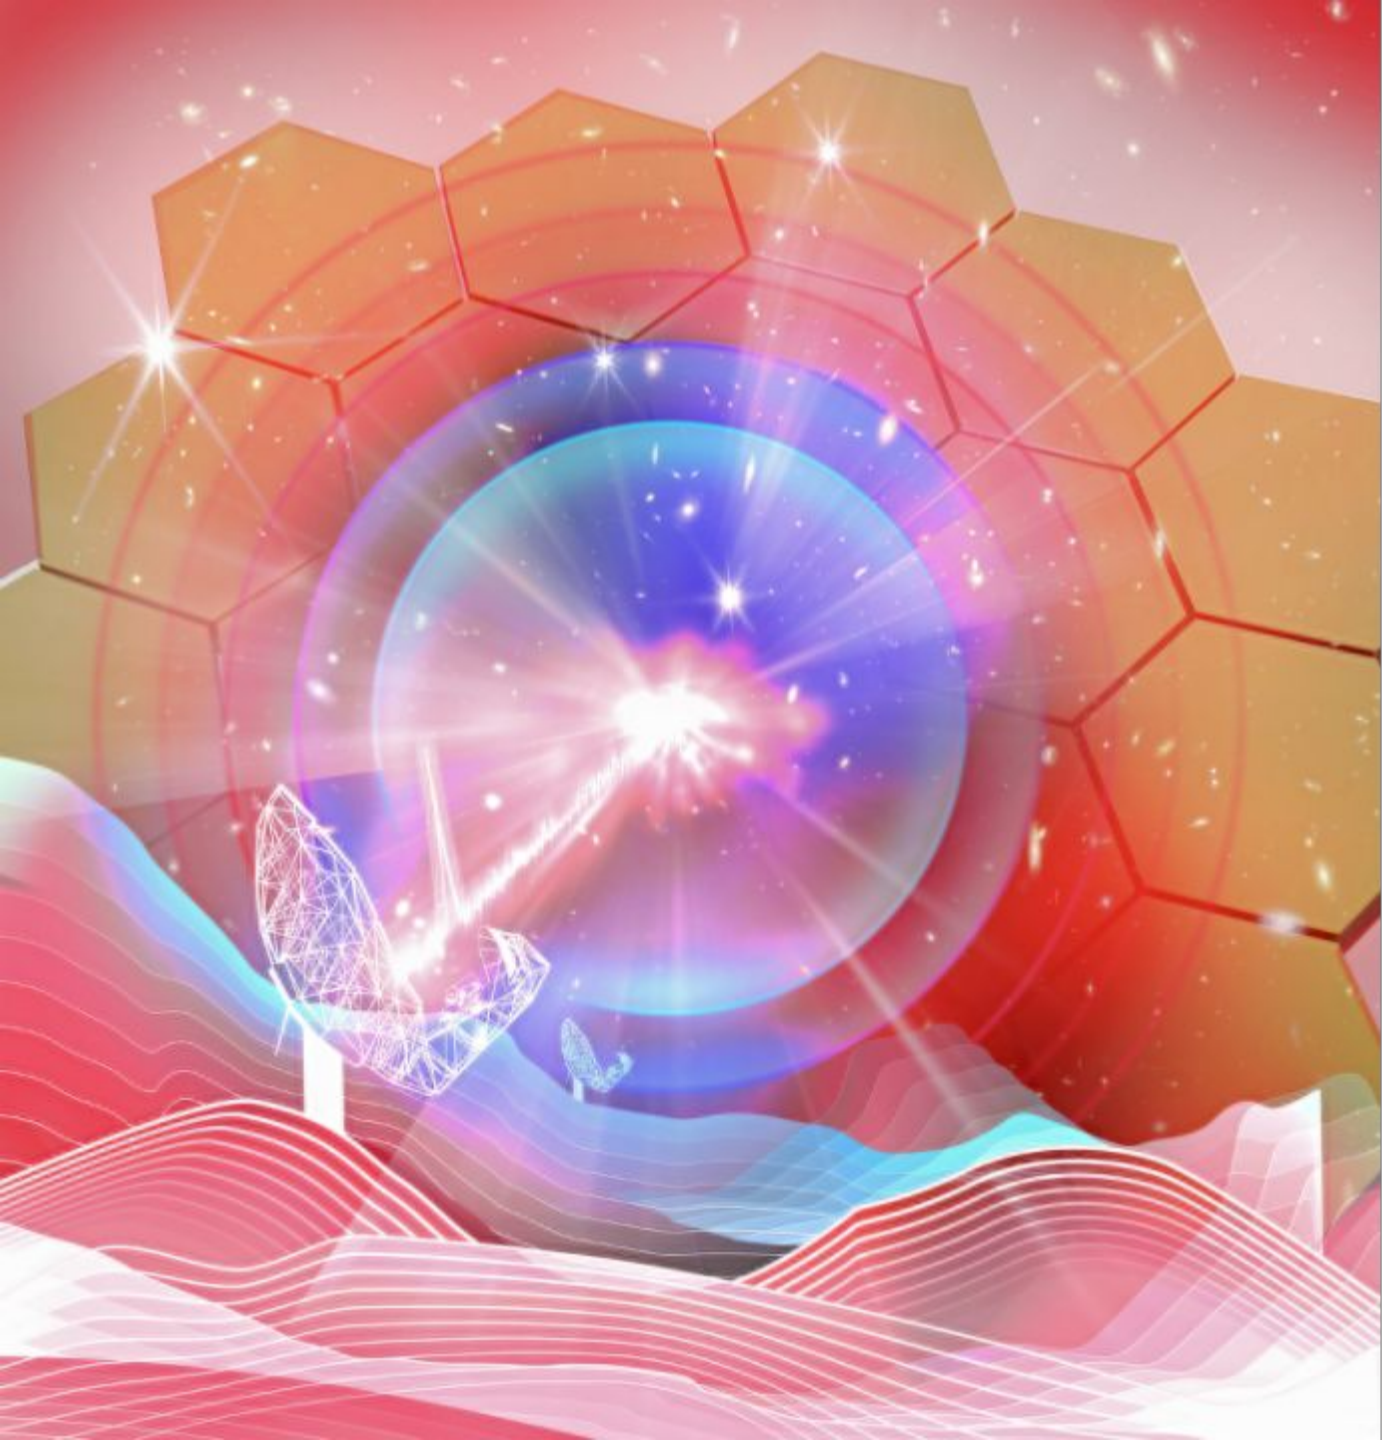
Bootcamp Data Engineer Nusacodes

Data Warehouse

Terstruktur dan Terpusat.

- **Format:** Data terstruktur sempurna.
- **Skema:** Validasi ketat saat penulisan.
- **Fokus:** Analitik BI operasional rutin.
- **Karakteristik:** Performa query sangat tinggi.
- **Kelemahan:** Biaya penyimpanan sangat mahal.





Data Lake

Mentah dan Skalabel.

- **Format:** Segala tipe data mentah.
- **Skema:** Validasi longgar saat pembacaan.
- **Fokus:** Eksplorasi Machine Learning.
- **Karakteristik:** Kapasitas objek sangat murah.

- **Kelemahan:** Rawan menjadi rawa data.

Dilema Dua Sistem

Memisahkan BI dan AI menciptakan masalah baru.



Silo Data

Data terpecah terpisah.



Biaya Ganda

Beban infrastruktur berganda.



Kompleksitas

Pipeline integrasi sangat rumit.

SOLUSI MODERN

Data Lakehouse

Menyatukan dua dunia berbeda.

- **Konsep:** Storage murah plus tata kelola.
- **Format:** Apache Iceberg atau Delta Lake.
- **Keamanan:** Dukungan penuh transaksi ACID.

- **Hasil:** Satu wadah analitik sentral.



Komparasi Langsung

Aspek	Data Warehouse	Data Lake	Data Lakehouse
Tipe Data	Terstruktur saja	Semua variasi format	Semua variasi format
Skala Biaya	Sangat mahal	Sangat terjangkau	Sangat terjangkau
Transaksi ACID	Terjamin	Tidak mendukung	Terjamin
Performa SQL	Sangat kilat	Sangat lambat	Sangat kilat
Dominasi Target	BI & Pelaporan	Machine Learning	BI & AI gabungan

Kapan Menggunakan Apa?

Pilih Warehouse

- ✓ Target dashboard harian.
- ✓ Metrik bisnis krusial.

Pilih Data Lake

- ✓ Tumpukan log mentah.
- ✓ Sains data absolut.

Pilih Lakehouse

- ✓ Integrasi BI dan AI.
- ✓ Efisiensi biaya infrastruktur.

KONVERGENSI PLATFORM DATA

Snowflake vs Databricks

Pertarungan dua arsitektur modern dalam menaklukkan ekosistem Lakehouse.

❄ Snowflake

Penguasa analitik instan dan berbagi data.

- **Paradigma:** Gudang data relasional terkelola penuh.
- **Bahasa Utama:** Pendekatan antarmuka SQL absolut.
- **Operasional:** Bebas konfigurasi infrastruktur kluster.
- **Target Pengguna:** Analis data dan Business Intelligence.
- **Format Terbuka:** Mengadopsi Apache Iceberg secara mendalam.





Databricks

Pelopor arsitektur Data Lakehouse terpadu.

- **Paradigma:** Penyatuan danau data berbasis mesin Spark.
- **Bahasa Utama:** Dukungan Python, Scala, R, dan SQL.
- **Keunggulan:** Pemrosesan streaming dan komputasi masif.

- **Target Pengguna:** Ilmuwan data dan rekayasawan data.
- **Format Terbuka:** Pencipta ekosistem Delta Lake.

Perbandingan Kapabilitas

Aspek Fokus	Snowflake	Databricks
Pengguna Utama	Analis Bisnis & BI	Data Scientist & Engineer
Kemudahan Operasional	Otomatis & Terkelola	Membutuhkan keahlian teknis
Kekuatan Inti	Kueri SQL interaktif kilat	Pelatihan Machine Learning
Arsitektur Dasar	Data Warehouse Murni	Data Lakehouse Adaptif
Format Bawaan	Apache Iceberg (Integrasi)	Delta Lake (Native)

Kapan Harus Memilih?

Pilih Snowflake jika...

- Kebutuhan absolut pada pelaporan dasbor BI.
- Tim mayoritas didominasi oleh analis SQL.
- Menolak kerumitan konfigurasi infrastruktur peladen.
- Membutuhkan pembagian data eksternal instan.

Pilih Databricks jika...

- Mengelola pipa data streaming skala masif.
- Fokus utama pada pelatihan model Kecerdasan Buatan.
- Tim memiliki keahlian rekayasa perangkat lunak.
- Membutuhkan eksekusi kode Python terintegrasi.

ARSITEKTUR DATA WAREHOUSE

Komponen Tabel Dimensional

Panduan peran Fact, Dimension, Bridge, Junk, dan Aggregate Table.

PETA KOMPONEN

Ekosistem Tabel Data

Fact Table

Penyimpanan metrik kuantitatif.

Dimension

Konteks deskriptif transaksi.

Bridge Table

Penanganan relasi banyak-ke-banyak.

Junk Dim

Wadah penggabungan indikator.

Aggregate

Ringkasan performa kueri.

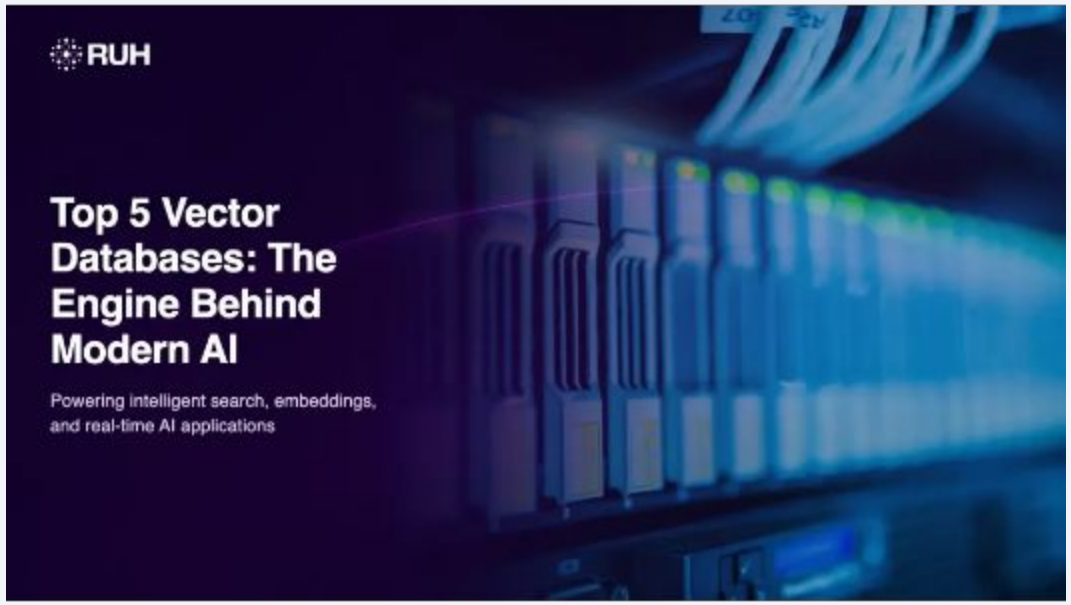
INTI PENGUKURAN

Fact Table

Pusat pencatatan nilai transaksi.

- **Fokus Metrik:** Menyimpan data angka terhitung.
- **Foreign Key:** Penghubung langsung ke dimensi.
- **Volume Baris:** Pertumbuhan data masif.





PEMBERI KONTEKS

Dimension Table

Penyedia kriteria penyaringan.

- **Atribut Teks:** Deskripsi rinci bisnis.
- **Struktur Kolom:** Tabel lebar berisikan teks.
- **Pertumbuhan:** Penambahan baris relatif lambat.

SOLUSI KOMPLEKSITAS

Bridge Table

Penjelajah relasi banyak-ke-banyak (Many-to-Many).

Tantangan Relasi

Satu transaksi memiliki banyak atribut. Contoh: satu klaim memiliki banyak diagnosis.

Peran Bridge

Tabel pemutus konflik relasi. Menghubungkan pasangan kunci tanpa merusak granulitas fakta.

EFISIENSI SKEMA

Junk Dimension

Penyederhanaan kumpulan indikator dan flag.

Penggabungan Flag

Kombinasi status transaksi tunggal.

Reduksi Kunci

Pengurangan kolom kunci asing.

Pembersihan Skema

Struktur tabel fakta rapi.

OPTIMALISASI KOMPUTASI

Aggregate Table

10x

Kecepatan akses dasbor analitik

Pra-Kalkulasi

Hasil agregasi tersimpan otomatis.

Beban Ringan

Pengurangan komputasi memori server.

Ringkasan Peran Tabel

Perbandingan fungsi dan karakteristik komponen tabel.

Tipe Tabel	Fungsi Utama	Karakteristik Data
Fact Table	Menyimpan angka	Banyak baris, sempit
Dimension Table	Menyimpan teks	Sedikit baris, lebar
Bridge Table	Menghubungkan M:N	Kumpulan kunci pasangan
Junk Dimension	Menyimpan status	Kombinasi flag tunggal
Aggregate Table	Menyimpan rangkuman	Ukuran data terkompresi

STRATEGI ARSITEKTUR WAREHOUSE

Pemodelan Skema Data

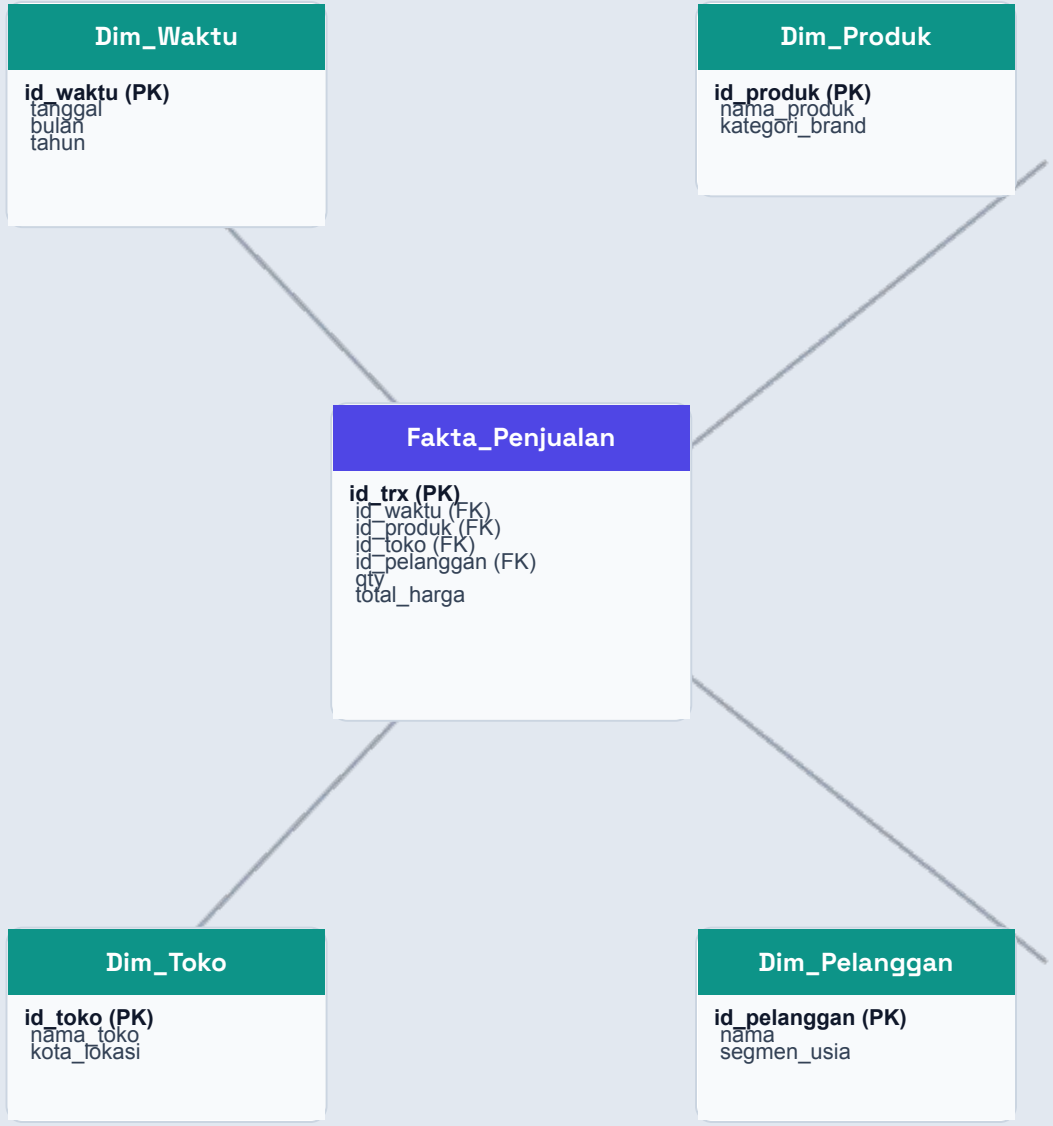
Menyeimbangkan kompleksitas, ruang penyimpanan, dan kecepatan kueri analitik.

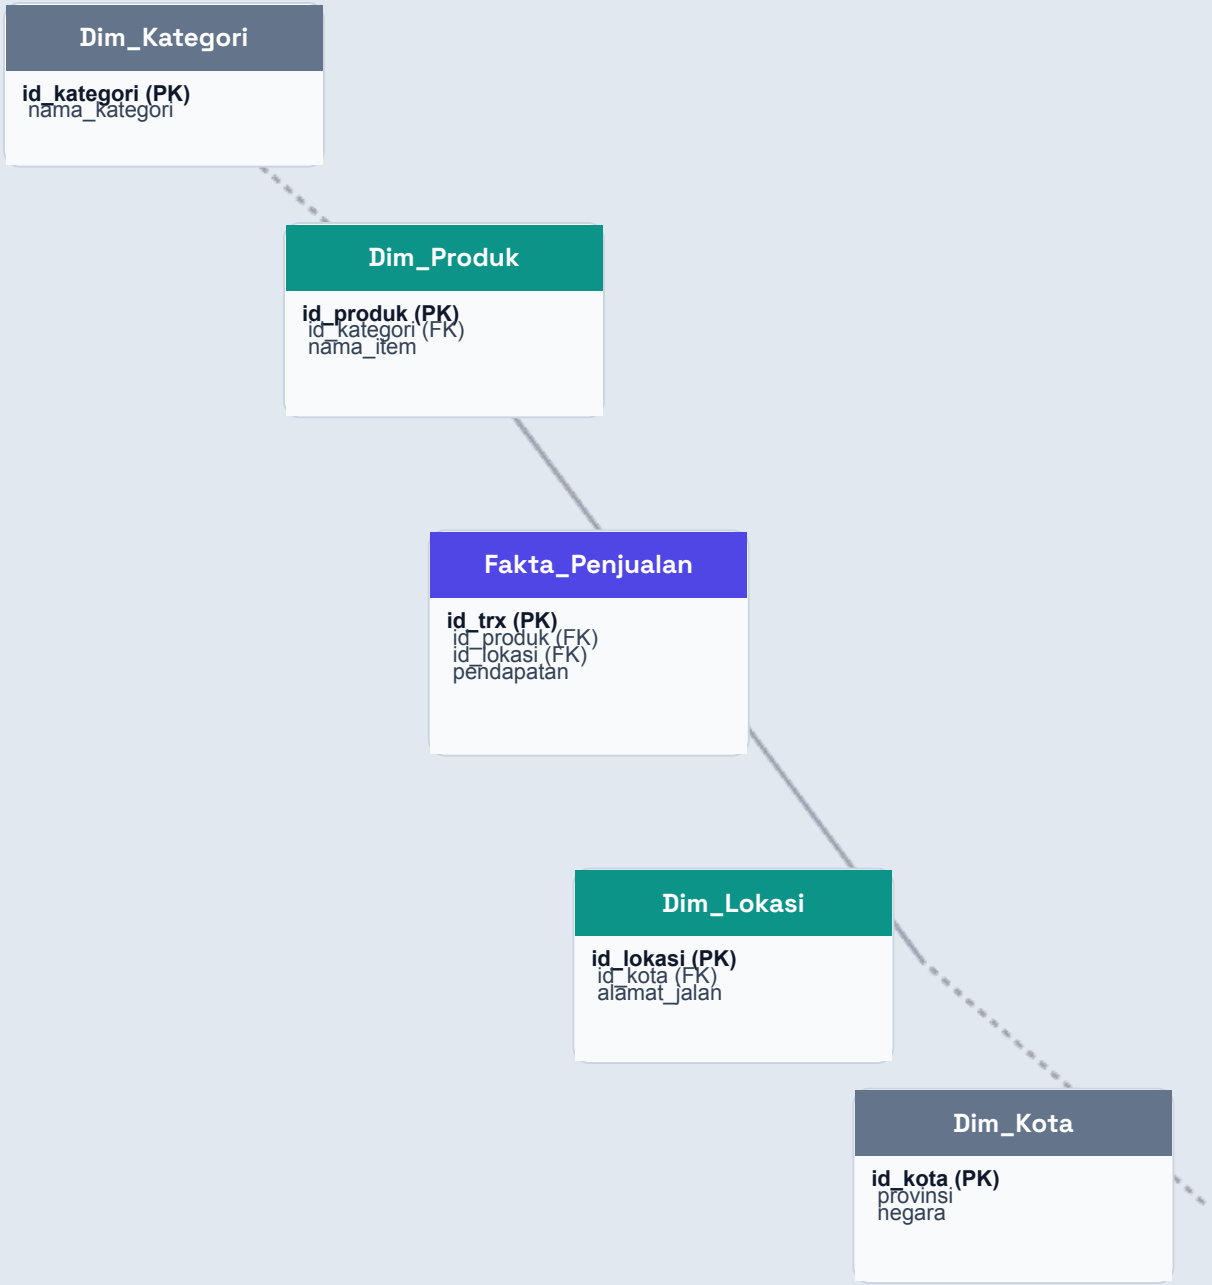
STANDAR EMAS INDUSTRI

Star Schema

Use Case: Pelaporan penjualan ritel harian. Query dasbor sangat cepat karena minim relasi tabel.

- **Arsitektur:** Satu fakta dikelilingi dimensi.
- **Lompatan:** Hanya satu JOIN per dimensi.
- **Kelebihan:** Eksekusi kueri sangat cepat.
- **Desain:** Intuitif untuk pengguna bisnis.





OPTIMALISASI PENYIMPANAN

Snowflake Schema

Use Case: Database perbankan asuransi lawas (On-Premise). Menyimpan hierarki wilayah agen dengan kapasitas penyimpanan sangat terbatas.

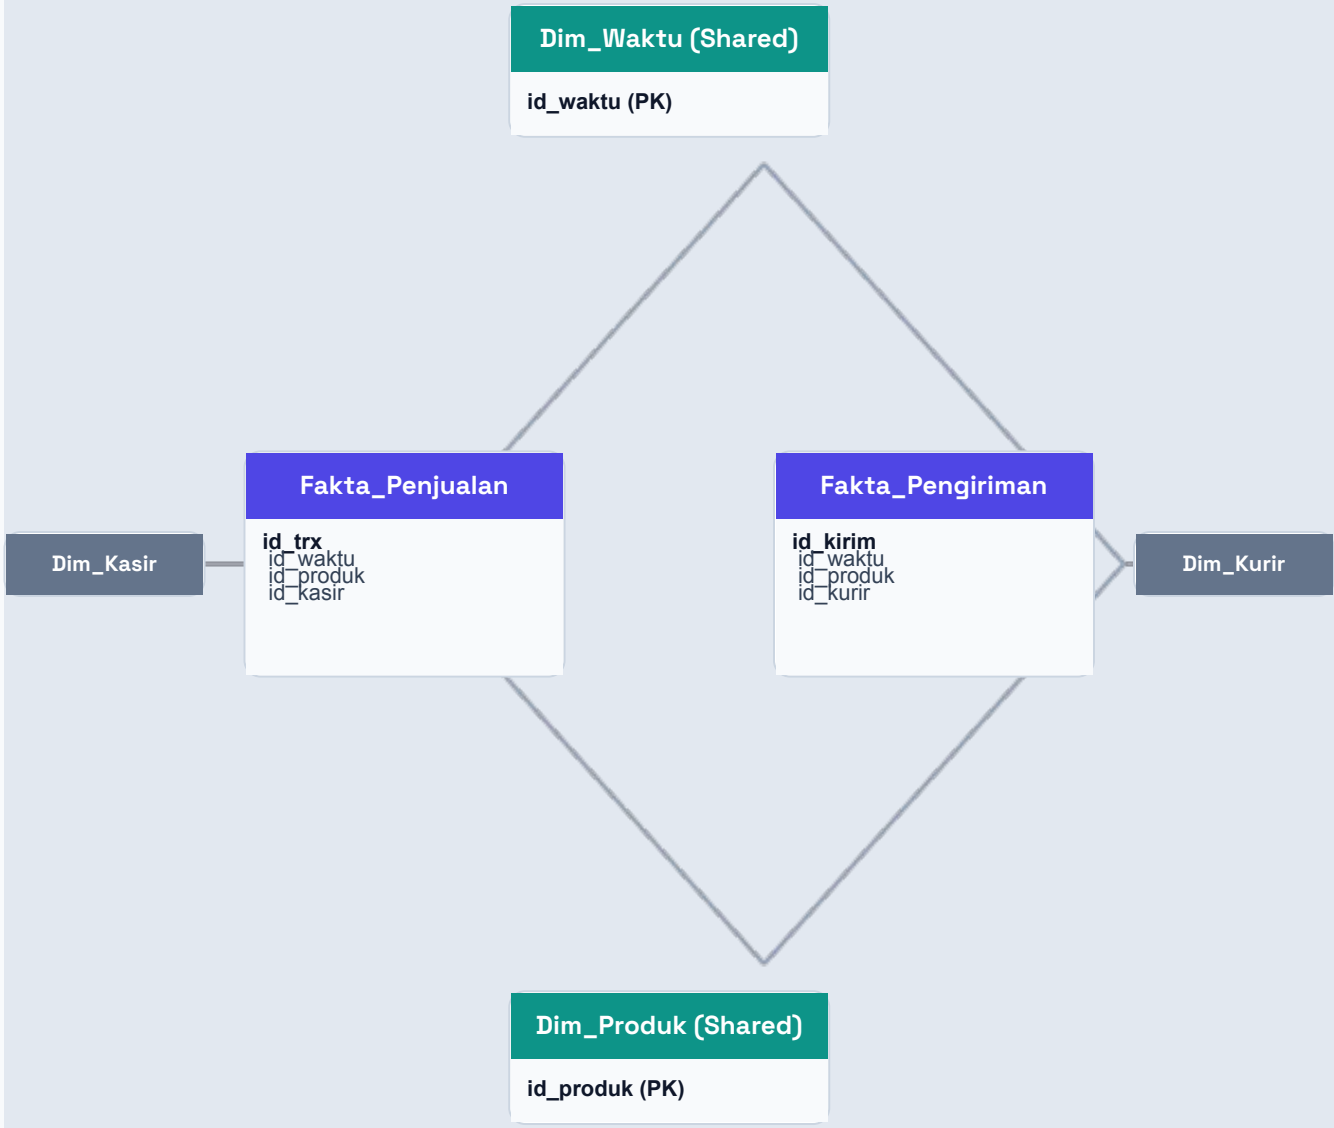
- **Arsitektur:** Dimensi dipecah (sub-dimensi).
- **Normalisasi:** Penghapusan data redundan.
- **Kelebihan:** Menghemat ruang penyimpanan.
- **Kelemahan:** Kueri lambat (banyak JOIN).

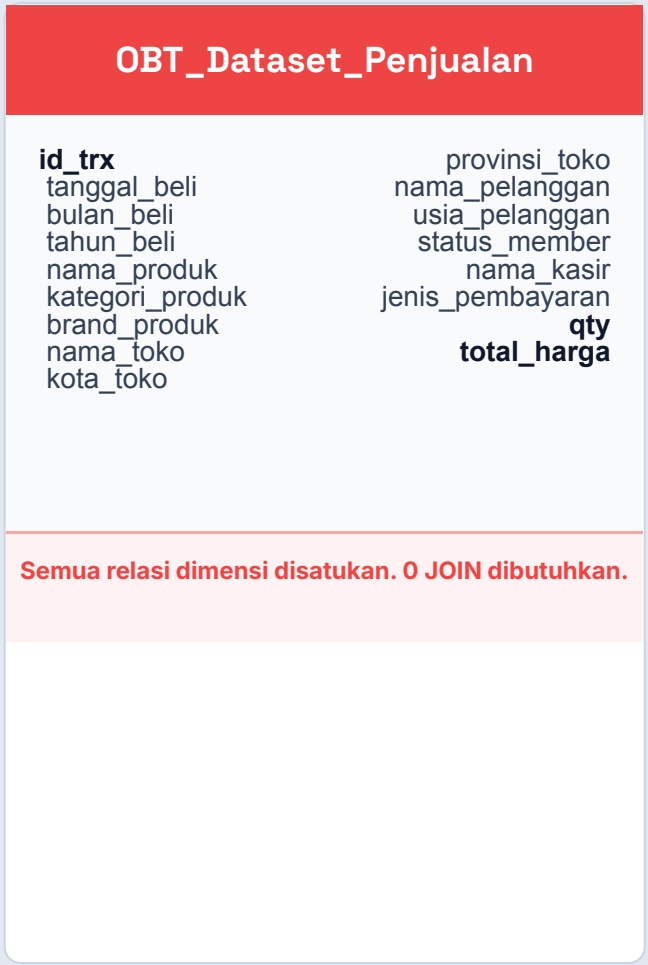
SKALA ENTERPRISE

Galaxy Schema

Use Case: Analisis logistik rantai pasok. Melacak satu produk dari titik perakitan, ke pengiriman, hingga penjualan (lintas proses bisnis).

- **Arsitektur:** Konstelasi multi-fakta.
- **Integrasi:** Berbagi dimensi (Conformed).
- **Kelebihan:** Analisis lintas proses bisnis.
- **Kelemahan:** Desain sangat kompleks.





EVOLUSI CLOUD MODERN

One Big Table

Use Case: Dasbor analitik *real-time streaming* di Google BigQuery / ClickHouse. Dirancang khusus untuk BI Tools.

- **Arsitektur:** Denormalisasi absolut tunggal.
- **Lompatan:** Tanpa operasi JOIN sama sekali.
- **Target:** Database kolumnar modern.
- **Kelemahan:** Redundansi data ekstrem.

Matriks Karakteristik

Skema	Kecepatan Kueri	Redundansi Data	Kompleksitas Desain
Star Schema	Tinggi	Sedang	Rendah
Snowflake Schema	Rendah	Sangat Rendah	Sedang
Galaxy Schema	Sedang	Sedang	Sangat Tinggi
One Big Table (OBT)	Sangat Tinggi	Sangat Tinggi	Sangat Rendah

Data naik kualitas dari Bronze ke Gold

Layer membantu memisahkan data mentah, data bersih, dan data siap bisnis.



Tidak harus selalu tiga tabel. Yang penting, tanggung jawab tiap layer jelas.

ALUR END-TO-END

Cleaning menjadi fondasi model analitik

Tahap awal menentukan kualitas data yang masuk ke warehouse atau lakehouse.



Quality gates: schema · missing values · duplicate · type · grain · join key